Stanciu Răducu-Ștefan · U13. Celula Urbana · Fenomenul: Insula de caldura si forma urbana

Întrebarea mea

Q13.4 Bucureștiul seamănă cu alt oraș (Cluj, Viena) ca structură termică?

Unitatea și sursele

Grid regulat de 250mx250m → Landsat 8/9 Collection 2 Level-2 + Sentinel-2 Level-2A (via Google Earth Engine) + OpenStreetMap (OSM) + Copernicus GHSL-BUILT-H + Copernicus GHSL-POP , Compozit sezonier de vară (Iunie – August)

Cui îi folosește răspunsul

Raspunsul intrebarii este folositor pentru primarii, finantatori, dar si pentru cercetatori climatici.

Unde am ajuns

Etapa curentă: alegere unitate de analiza, surse si intrebare

Făcut de la ultimul checkpoint:

Ce am schimbat față de plan: nimic

DOVADA ETAPEI

Extragerea și structurarea metadatelor scenelor satelitare într-un tabel comparativ (Vara 2023 — București)

```
import ee
import pandas as pd

# 1. Punct central București
bucuresti_center = ee.Geometry.Point([26.1025, 44.4268])

# 2. Colecții filtrate (Vara 2023)
landsat_summer = (ee.ImageCollection('LANDSAT/LC08/C02/T1_L2')
                  .filterBounds(bucuresti_center)
                  .filterDate('2023-06-01', '2023-08-31')
                  .filter(ee.Filter.lt('CLOUD_COVER', 20)))

sentinel_summer = (ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED')
                   .filterBounds(bucuresti_center)
                   .filterDate('2023-06-01', '2023-08-31')
                   .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 20)))

# 3. Funcții helper pentru extragerea proprietăților tabulare
def get_landsat_metadata(img):
    return ee.Feature(None, {
        'Satelit': 'Landsat 8 (TIRS/OLI)',
        'Tip_Date': 'Termic (LST) & Refl.',
        'Data_Achizitie': img.get('DATE_ACQUIRED'),
        'Acoperire_Nori_%': ee.Number(img.get('CLOUD_COVER')).round(),
        'Scene_ID': img.get('system:index')
    })

def get_sentinel_metadata(img):
    # Sentinel stochează data în timestamp milisecunde
    date_str = ee.Date(img.get('system:time_start')).format('YYYY-MM-dd')
    return ee.Feature(None, {
        'Satelit': 'Sentinel-2 (MSI)',
        'Tip_Date': 'Optic (NDVI / NDBI)',
        'Data_Achizitie': date_str,
        'Acoperire_Nori_%': ee.Number(img.get('CLOUDY_PIXEL_PERCENTAGE')).round(),
        'Scene_ID': img.get('system:index')
    })

# 4. Mapare și extragere în Python
l8_features = landsat_summer.map(get_landsat_metadata).getInfo()['features']
s2_features = sentinel_summer.map(get_sentinel_metadata).getInfo()['features']

# 5. Construire DataFrame
rows = [f['properties'] for f in l8_features] + [f['properties'] for f in s2_features]
df_scene = pd.DataFrame(rows)

# Sortare cronologică
df_scene['Data_Achizitie'] = pd.to_datetime(df_scene['Data_Achizitie'])
df_scene = df_scene.sort_values(by=['Data_Achizitie', 'Satelit']).reset_index(drop=True)
```

```
# Sortare cronologică
df_scene['Data_Achizitie'] = pd.to_datetime(df_scene['Data_Achizitie'])
df_scene = df_scene.sort_values(by=['Data_Achizitie', 'Satelit']).reset_index(drop=True)

# Reordonare coloane
df_scene = df_scene[['Data_Achizitie', 'Satelit', 'Tip_Date', 'Acoperire_Nori_%', 'Scene_ID']]

# Afișare tabel formatat în notebook
display(df_scene)
```

	Data_Achizitie	Satelit	Tip_Date	Acoperire_Nori_%	Scene_ID
0	2023-06-06	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	7	LC08_182029_20230606
1	2023-06-22	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	9	LC08_182029_20230622
2	2023-06-24	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	1	20230624T090601_20230624T091055_T35TMK
3	2023-06-29	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	13	LC08_183029_20230629
4	2023-06-29	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	9	20230629T090559_20230629T091459_T35TMK
5	2023-07-04	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	12	20230704T090601_20230704T091054_T35TMK
6	2023-07-09	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	4	20230709T090559_20230709T091057_T35TMK
7	2023-07-14	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	0	20230714T090601_20230714T091057_T35TMK
8	2023-07-15	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	15	LC08_183029_20230715
9	2023-07-19	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	17	20230719T090559_20230719T091058_T35TMK
10	2023-07-24	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	2	LC08_182029_20230724
11	2023-07-24	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	3	20230724T090601_20230724T091054_T35TMK
12	2023-07-29	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	13	20230729T090559_20230729T091058_T35TMK
13	2023-08-03	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	0	20230803T090601_20230803T091014_T35TMK
14	2023-08-09	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	9	LC08_182029_20230809
15	2023-08-13	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	6	20230813T090601_20230813T091738_T35TMK
16	2023-08-18	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	20	20230818T090559_20230818T091720_T35TMK
17	2023-08-23	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	0	20230823T090601_20230823T091022_T35TMK
18	2023-08-25	Landsat 8 (TIRS/OLI)	Termic (LST) & Refl.	3	LC08_182029_20230825
19	2023-08-28	Sentinel-2 (MSI)	Optic (NDVI / NDBI)	0	20230828T090559_20230828T091557_T35TMK

CP1: data card + tabelul aliniat + acoperirea · CP2: matricea X + scree/loadings · CP3: harta relațiilor + protocolul · CP4: o sursă vs. toate, cu intervale + ablație · CP5: figura centrală · CP6: demo din explorator

Cum se verifică

Repo / notebook: [link]

Surse: [Landsat 8/9 C2 T1 (LST), Collection 2 Level-2, Iun–Aug 2023]

[Sentinel-2 L2A (NDVI, NDBI), Level-2A Harmonized, Iun–Aug 2023]
Unitate × pas de timp: Celulă grid 250mx250m

Split: [Spațial / LOYO (Leave-One-City-Out: antrenare pe București, testare/evaluare pe Cluj / Viena)]

Seed-uri / rulări: [n]

Baseline „o singură sursă”: [valoare]

Ce înseamnă rezultatul: Am reusit sa ma conectez la Google Earth Engine si sa accesez datele satelitare Landsat 8 si Sentinel-2.

Articole:

1. Local Climate Zones for Urban Temperature Studies [2012] – demonstrează că studiul insulei de căldură urbane (UHI) nu trebuie făcut la nivel de micro-obiect (un singur acoperiș) și nici macroscopic la scară regională, ci la scara de 200–500 m
2. Quantifying the influence of 2D and 3D urban morphology on the thermal environment across climatic zones [2022] - Demonstrează că adăugarea parametrilor morfologici 3D peste metricele clasice crește acuratețea explicării temperaturii de suprafață (cu peste 21%) și validează utilizarea modelelor de regresie bazate pe arbori (BRT/XGBoost) pe date eterogene raster-vector.

Blocaje și următorii pași la CP[n+1]

Blocaje

1. Accesarea datelor -> M-am conectat la Google Earth Engine -> Accesarea datelor a fost realizata.

Planul pe 2 săptămâni

Săptămâna [4]: Alegerea perioadei, a rezolutiei temporale/spatiale , tabelul SOA cu 10 articole.